

Как устроено решение, простыми словами

Объяснение с самого начала и по порядку, для тех, кто не занимается машинным обучением и лингвистикой. Каждое новое понятие объясняется там, где появляется впервые.

- | | |
|--|------------------------------------|
| 1. Зачем это нужно | 9. Как измерить смысл |
| 2. Данные, классы и метки | 10. Что показали смысловые метрики |
| 3. Как превратить текст в числа | 11. Что такое классификатор |
| 4. Синтаксический разбор на пальцах | 12. Как честно проверить модель |
| 5. Какие числа даёт Profiling-UD | 13. Как считать качество |
| 6. Как понять, что признак что-то значит | 14. Результаты |
| 7. Что нашлось | 15. Где модель ошибается |
| 8. Ловушка с длиной | 16. Итог |

1. Зачем это нужно

Языковая модель, например ChatGPT, это программа, которая умеет продолжать текст. Она прочитала огромное количество книг, статей и сайтов и научилась угадывать, какое слово обычно идёт следующим. Если раз за разом добавлять самое подходящее слово, получается связный текст, в том числе научный.

Проблема в том, что такой текст выглядит вполне правдоподобно. Журналам, преподавателям и рецензентам хочется понимать, кто написал статью или аннотацию, человек или программа. На глаз это получается плохо, поэтому ищут автоматические способы.

В задании было три шага:

1. найти свойства текста, по которым человек и модель пишут по-разному;
2. сравнить тексты по смыслу;
3. научить компьютер по этим свойствам отличать один текст от другого и проверить, насколько хорошо у него получается.

2. Данные, классы и метки

Чтобы чему-то учить компьютер, нужны примеры с правильными ответами. Это тексты, про которые точно известно, кто их написал.

Класс. Группа, к которой относится текст: «написал человек», «написала модель». **Метка** это правильный ответ для конкретного текста, то есть название его класса. **Датасет** это набор текстов вместе с метками.

Я работала с двумя готовыми датасетами.

Английский (AIGTxt). Исследователи взяли абзацы из настоящих научных статей и попросили ChatGPT пересказать каждый своими словами. Потом склеили третий вариант: половина абзаца от человека, половина от ChatGPT. Так у каждого абзаца получилось три версии: человеческая, машинная и смешанная. Это удобно, потому что пересказ можно прямо сравнить с оригиналом.

Русский (AINL-Eval-2025). Аннотации научных статей, то есть короткие описания в начале статьи. Часть написана авторами статей, остальные сгенерировали три разные модели (gpt-4-turbo, llama и gemma), которым дали только название статьи и ключевые слова. Пар здесь нет, каждая модель писала свой текст с нуля.

Из каждого датасета я взяла несколько тысяч текстов: 4500 английских и 4800 русских. Каждого источника поровну. Но в русском, если делить только на «человек» и «модель», машинных текстов получается втрое больше, ведь моделей три.

3. Как превратить текст в числа

Компьютер не понимает текст так, как человек. Зато он отлично работает с числами. Поэтому первый шаг любой такой работы это описать каждый текст набором чисел.

Признак. Одно число, которое описывает какое-то свойство текста. Набор признаков для одного текста похож на анкету: длина слов такая-то, доля глаголов такая-то, и так далее. Дальше всё решение работает только с этими анкетами.

ПРИМЕР
Текст «Модель пишет короткие аннотации. Они похожи.» Признаки: предложений 2, слов 6, средняя длина слова 6.2 буквы, глаголов 1 из 6, то есть 17%. Уже по таким простым числам тексты разных авторов начинают различаться.

Простых признаков вроде длины слова мало. Интереснее то, как устроены предложения: сколько в них придаточных, далеко ли слова стоят от тех, к которым относятся, какой порядок слов. Чтобы это посчитать, нужен разбор предложения.

4. Синтаксический разбор на пальцах

Все помнят со школы разбор предложения по членам: где подлежащее, где сказуемое, какое слово к какому относится. Компьютер умеет делать то же самое автоматически.

Universal Dependencies (UD). Международный стандарт такого разбора, одинаковый для всех языков. Каждое слово получает часть речи, грамматические формы (время, лицо, число) и «хозяина», то есть слово, от которого оно зависит. У главного слова предложения хозяина нет, его называют корнем.

Вот как выглядит разбор предложения «Модель пишет короткие аннотации»:

№	Слово	Часть речи	Зависит от	Роль	Длина связи
1	Модель	существительное	пишет (2)	подлежащее	1
2	пишет	глагол	ни от кого	корень	—
3	короткие	прилагательное	аннотации (4)	определение	1
4	аннотации	существительное	пишет (2)	дополнение	2

Если нарисовать стрелки от хозяина к зависимому, получится дерево. Длина связи это расстояние в словах между хозяином и зависимым: у «аннотации» и «пишет» оно равно двум. В длинных запутанных предложениях связи тянутся через десять-двадцать слов, в простых они короткие. Такие вещи и превращаются в признаки.

Для разбора я использовала готовую программу stanza. Она обучена на вручную размеченных текстах и разбирает около тысячи предложений в минуту. Разбор не идеален, но ошибается редко.

5. Какие числа даёт Profiling-UD

Profiling-UD это инструмент из задания. Он берёт такие разборы и считает по ним около ста признаков. У него есть только сайт с формой загрузки, и из программы к нему не обратиться, поэтому я посчитала те же самые признаки своим кодом, с теми же названиями и по тем же правилам. У меня вышло 99 признаков. Вот главные группы с примерами:

Группа	Признак	Что значит
Текст	char_per_tok	средняя длина слова в буквах
Лексика	TTR	сколько разных слов на каждые 100 слов. Если автор повторяется, TTR низкий
Лексика	lexical_density	доля «смысловых» слов (существительные, глаголы, прилагательные) среди всех
Части речи	upos_dist_NUM	доля чисел среди всех слов
Глагол	verbs_tense_dist_Past	доля глаголов в прошедшем времени
Синтаксис	avg_links_len	средняя длина связи, как в таблице выше
Синтаксис	subj_pre	как часто подлежащее стоит перед сказуемым
Синтаксис	avg_max_depth	глубина дерева, то есть сколько уровней вложенности

Большинство признаков это доли в процентах. Так тексты разной длины можно сравнивать честно: в длинном тексте просто больше слов, а доля от длины не зависит.

6. Как понять, что признак что-то значит

Итак, у каждого текста есть 99 чисел. Теперь для каждого признака нужно понять, различается ли он у людей и у моделей. Сравнить средние мало. Тексты сильно отличаются друг от друга, и небольшая разница средних может получиться чисто случайно.

Статистический тест и p-value. Тест отвечает на вопрос: если бы на самом деле разницы не было, насколько вероятно случайно увидеть такую, как у нас? Эта вероятность и называется p-value. Если она меньше 5%, разницу называют значимой, то есть скорее настоящей, чем случайной. Я использовала тест Манна–Уитни, который сравнивает не средние, а порядок значений, и поэтому не боится редких выбросов.

Поправка на множественные сравнения. Если проверить сто признаков, то даже при полном отсутствии разницы примерно пять из них окажутся «значимыми» по чистой случайности. Поправка Бенджамини–Хохберга ужесточает порог так, чтобы таких ложных находок было мало.

Есть и обратная сторона. Когда текстов тысячи, тест замечает даже крошечную разницу, которая на практике ничего не значит. Поэтому, кроме значимости, я смотрела на размер эффекта.

Размер эффекта, дельта Клиффа. Берём случайный ИИ-текст и случайный человеческий и смотрим, у кого значение признака больше. Повторяем так для всех пар. Дельта равна доле пар, где больше у ИИ, минус доля пар, где больше у человека. Получается число от -1 до 1.

ПРИМЕР

Если в 80% пар слова у ИИ-текста длиннее, а в 20% короче, дельта равна $0.8 - 0.2 = 0.6$. Это большой эффект: по одному этому признаку уже можно неплохо угадывать. Если бы было 55% против 45%, дельта вышла бы 0.1, и такой признак почти ничего бы не давал.

Принятые пороги такие: до 0.15 эффекта нет, до 0.33 малый, до 0.47 средний, выше большой.

Некоторые признаки почти повторяют друг друга. Например, есть четыре варианта TTR, и они сильно связаны между собой. Чтобы не считать одно и то же несколько раз, я оставила по 20 самых сильных признаков на язык, выбрасывая те, что почти копируют уже взятые.

Корреляция. Число от -1 до 1, которое показывает, насколько два показателя меняются вместе. Около 1 значит: растёт один, растёт и другой. Около -1: растёт один, падает другой. Около 0: связи нет.

7. Что нашлось

Значимыми оказались почти все признаки: 71 из 92 в английском и 83 из 92 в русском. Заметный эффект был у 10 и 14 признаков соответственно. Вот что они говорят простыми словами.

Английский, где ChatGPT пересказывал

Что	человек	ChatGPT
Средняя длина слова, букв	5.3	5.8
Вспомогательные глаголы (is, has, will), %	4.0	2.6
Связка «X is Y», %	1.2	0.6
Разнообразие слов, TTR	0.68	0.72
Предложений, где главное слово это глагол, %	78	88

ChatGPT при пересказе меняет простые слова на длинные книжные (условно, «use» на «utilize») и не любит конструкции вида «это является тем-то», предпочитая строить фразу вокруг действия. Слова он повторяет реже и заменяет их синонимами.

Русский, где модели писали с нуля

Что	человек	модели
Средняя длина связи между словами	2.45	2.08
Самая длинная связь в предложении	19.6	12.4
Союзы «и», «а», «но», %	3.5	5.1
Числа, %	1.30	0.20
Глаголы в прошедшем времени, %	44	27
Подлежащее стоит первым, %	47	67

Модели пишут проще: связи короче, части фразы склеиваются через «и», порядок слов прямой. Условно, человек пишет «В работе исследовано...», а модель «Исследование показывает...». Чисел у моделей почти нет, и это понятно: модель видела только название статьи и не знает, какие в ней получились результаты. Прошедшее время у человека встречается чаще, потому что он рассказывает о сделанной работе, а модель описывает её в общем.

Важное наблюдение: общего для всех языков набора признаков нет. Например, причастий у ChatGPT в английском больше, чем у людей, а у моделей в русском меньше. Похожа только общая тенденция: синтаксис проще, лексика плотнее.

Смешанные английские тексты по всем признакам оказались ровно посередине между человеком и ChatGPT. Так и должно быть, ведь они склеены из двух половин.

8. Ловушка с длиной

В русском датасете есть подвох. Человеческие аннотации заметно длиннее машинных: в среднем 100 слов против 62–84. А многие признаки зависят от длины сами по себе. Например, в длинном тексте больше шансов встретить очень длинное предложение и, значит, очень длинную связь.

Смешивающий фактор. Третья причина, которая влияет и на признак, и на класс. Из-за неё может показаться, что признак отличает классы, хотя на самом деле он просто повторяет этот третий фактор. Классический пример: продажи мороженого и число утонувших растут вместе, но причина у обоих одна, жара.

Я проверила длину двумя способами.

Первый способ: убрать влияние длины. Для каждого признака я посчитала, какую часть его изменений можно объяснить одной длиной, и вычла её. После этого снова посмотрела на связь с классом. Это называется частной корреляцией. У большинства признаков связь почти не изменилась, у некоторых даже выросла. Заметно упала она только у «самой длинной связи», как и ожидалось.

Второй способ: дать модели только длину. Если классификатор по одной длине угадывает почти так же хорошо, как по всем признакам, значит признаки ничего не добавляют. Оказалось, длина сама по себе действительно много подсказывает (об этом в разделе 14), но остальные признаки добавляют к ней заметно больше.

Вывод такой: различия в стиле настоящие, но о длине нужно помнить. В английском этой проблемы нет, там все три версии абзаца примерно одной длины.

9. Как измерить смысл

Признаки выше описывают форму текста. Второй шаг задания касается смысла: насколько тексты похожи по содержанию и насколько они однообразны. Для этого нужны нейросети.

Эмбединг, или вектор смысла. Нейросеть превращает слово (или целый текст) в набор из нескольких сотен чисел, причём похожие по смыслу слова получают похожие наборы. «Кошка» и «котёнок» окажутся рядом, «кошка» и «налог» далеко. Похожесть двух таких наборов измеряют косинусом: 1 значит полное совпадение по смыслу, 0 значит никакой связи.

BERTScore. Берём два текста и для каждого слова одного ищем самое похожее по смыслу слово в другом. Усредняем похожести и получаем оценку близости текстов по смыслу, даже если слова в них разные. Я пользовалась версией, где 0 примерно соответствует случайной паре текстов, а 1 полному совпадению.

BARTScore. Другая нейросеть, BART, умеет переписывать один текст в другой. Мы спрашиваем её, насколько вероятно получить текст Б из текста А. Если Б это пересказ А, вероятность высокая. Если Б про что-то совсем другое, низкая. Значения отрицательные, и чем ближе к нулю, тем ближе тексты.

Self-BLEU. BLEU считает, сколько сочетаний из одного, двух, трёх и четырёх слов подряд совпадает у двух текстов. Self-BLEU сравнивает каждый текст класса с другими текстами того же класса. Если тексты повторяют одни и те же обороты, значение высокое. Это мера шаблонности.

Перплексия. Языковая модель читает текст и на каждом слове угадывает, каким оно будет. Перплексия показывает, насколько часто модель удивлялась. У предсказуемого текста она низкая.

ПРИМЕР

После «Полученные результаты могут быть» почти любая модель уверенно ждёт «использованы». Если так и написано, удивления нет. Человек чаще пишет что-то неожиданное, поэтому у человеческого текста перплексия обычно выше.

Кроме метрик из задания я придумала несколько своих:

- **Угадываемость по началу.** Даём нейросети BART первое предложение и спрашиваем, насколько вероятен остальной текст. Так можно измерить предсказуемость текста, даже когда нет оригинала для сравнения.
- **Burstiness, неровность.** Считаем перплексию отдельно по каждому предложению и смотрим, как сильно она скачет. Человек пишет неровно: одно предложение простое, другое необычное. Модель пишет ровнее.
- **Разнообразие словаря** внутри одного текста (MTLD): как быстро автор начинает повторять уже использованные слова.

10. Что показали смысловые метрики

Метрика	Английский	Русский
BERTScore с оригиналом	пересказ 0.66, смешанный 0.81, чужой текст на ту же тему -0.10	оригиналов нет
BARTScore с оригиналом	пересказ -1.9, смешанный -1.1, чужой текст -4.1	оригиналов нет
Self-BLEU, шаблонность	у всех около 0.10	модели 0.13–0.15, люди 0.05
Угадываемость по началу	почти одинаковая	у моделей заметно выше
Перплексия	у ChatGPT ниже	почти одинаковая
Неровность	у ChatGPT чуть ниже	у моделей заметно ниже

Здесь две истории.

Пересказ сохраняет смысл. По BERTScore пересказ ChatGPT близок к оригиналу (0.66), а чужой текст на ту же научную тему не близок совсем (-0.10). BARTScore говорит то же самое. Значит, ChatGPT не выдумывает новое, а меняет форму: слова и строение фраз.

Текст, написанный с нуля, шаблонен. В русском модели втрое чаще повторяют одни и те же обороты, чем люди. Их тексты больше похожи друг на друга, легче угадываются по первому предложению и ровнее по перплексии. Типичные обороты моделей: «имеет важное значение для», «результаты показывают, что», «может быть использовано для разработки». В английском шаблонности не видно, потому что ChatGPT шёл за чужим текстом и повторял его структуру.

Ещё я посмотрела на эмбединги целых текстов. Облака человеческих и машинных текстов полностью перекрываются, то есть темы у них одни и те же. Отличается не то, о чём написано, а то, как.

11. Что такое классификатор

Третий шаг: научить компьютер по признакам самому решать, кто написал текст.

Классификатор. Программа, которая по анкете из чисел выдаёт класс. Сначала её обучают: показывают тысячи анкет с правильными ответами, и она подбирает внутренние настройки так, чтобы ошибаться как можно реже. Потом ей дают новые анкеты без ответов, и она предсказывает сама.

Я сравнила четыре классификатора, которые по-разному проводят границу между классами:

Модель	Как думает, на пальцах
Логистическая регрессия	Каждому признаку назначается вес: «длинные слова +0.5, связки -0.3». Веса складываются, и сумма решает, какой класс. Простая и понятная.
SVM	Ищет границу между классами с самым широким «коридором» до ближайших примеров. Умеет проводить кривые границы.
Случайный лес	Строит сотни деревьев вопросов вида «длина слова больше 5.5? если да, то...». Каждое дерево голосует, побеждает большинство.
XGBoost	Тоже деревья, но строятся по очереди: каждое следующее исправляет ошибки предыдущих. Обычно одна из самых сильных моделей для таблиц.

Каждый классификатор я обучала на нескольких наборах признаков, чтобы понять, что именно даёт результат: только длина, все 99 признаков Profiling-UD, 20 лучших признаков, признаки из смысловых метрик (перплексия, неровность, разнообразие словаря) и всё вместе.

Для сравнения были две базовые линии.

Базовая линия. Простое решение, с которым сравнивают основное. Если основное не лучше простого, значит сложность не окупилась.

- **TF-IDF.** Классификатор вообще без лингвистики, который смотрит только на то, какие слова и пары слов встречаются в тексте. Редким словам даётся больший вес, чем частым вроде «и» или «в».
- **Метод из бенчмарка mgt-detection-benchmark.** Один-единственный признак, насколько языковая модель в среднем «не уверена» в словах текста, и на нём случайный лес.

12. Как честно проверить модель

Если проверять классификатор на тех же текстах, на которых он учился, он покажет отличный результат: просто запомнит ответы, как школьник, выучивший ответы к билетам. Поэтому проверять нужно на текстах, которых он не видел.

Кросс-валидация. Данные делятся на пять равных частей. Модель учится на четырёх и проверяется на пятой. Так повторяется пять раз, чтобы каждая часть побыла проверочной, и результаты усредняются. Каждый текст проверяется ровно один раз, и всегда моделью, которая его не видела.

В английском датасете есть тонкость. Три версии одного абзаца говорят об одном и том же. Если человеческая версия попадёт в обучение, а пересказ в проверку, модель может узнать пересказ по теме («а, это про стеганографию, я такой видела») и не смотреть на стиль. Результат выйдет завышенным. Поэтому я следила, чтобы все три версии одного абзаца всегда попадали в одну и ту же часть.

Утечка данных. Ситуация, когда при проверке модели каким-то путём достаётся информация о правильном ответе. Результат при этом выглядит лучше, чем будет на самом деле. Это одна из самых частых ошибок в машинном обучении.

13. Как считать качество

Самая простая мера это **точность (accuracy)**, доля правильных ответов. Но она обманчива, если классов неравное количество. В русском датасете машинных текстов втрое больше, чем человеческих, и модель, которая всегда отвечает «машина», наберёт 75% точности, ничего не понимая.

Precision и recall. Возьмём класс «человек». Precision (точность ответа) показывает, какая доля текстов, названных человеческими, действительно человеческие. Recall (полнота) показывает, какую долю всех человеческих текстов модель нашла. **F1** объединяет обе меры в одну и получается высоким, только когда высоки обе.

Macro F1. F1 считается отдельно для каждого класса, а потом усредняется. Каждый класс весит одинаково, и модель уже не может набрать высокий балл, игнорируя маленький класс. 0.5 в задаче с двумя классами это уровень подбрасывания монетки, 1.0 значит идеально.

14. Результаты

Задача	только длина	Profiling-UD	+ смысловые	TF-IDF	бенчмарк
en: человек или ИИ	0.57	0.84	0.87	0.95	0.57
en: человек, ИИ, смешанный	0.37	0.59	0.63	0.67	0.37
ru: человек или ИИ	0.82	0.92	0.93	0.93	0.47
ru: какая из четырёх	0.58	0.82	0.84	0.93	0.27

Macro F1 лучшего из четырёх классификаторов. Для трёх классов случайный уровень около 0.33, для четырёх около 0.25.

Как читать таблицу:

- **Лингвистика работает.** Одни синтаксические признаки дают 0.84 на английском и 0.92 на русском. Это намного лучше случайного угадывания.
- **Смысловые признаки помогают.** Добавление перплексии и неровности поднимает результат ещё на 1–4 пункта. Значит, они замечают то, чего нет в синтаксисе.
- **Длина в русском подсказывает многое (0.82),** но лингвистика добавляет к ней ещё 10 пунктов, а когда нужно узнать конкретную модель, целых 24.
- **Одного признака мало.** Метод из бенчмарка почти бесполезен: в русском он просто всё называет машинным.
- **Слова сильнее всего.** TF-IDF выигрывает, потому что у каждой модели есть любимые слова и обороты, которые выдают её сразу. Зато по нему не понять, чем стиль отличается, а лингвистические признаки это объясняют.

Среди четырёх классификаторов разница небольшая, чаще всех выигрывал SVM.

Напоследок я проверила, на какие признаки классификатор опирается сильнее всего, с помощью метода SHAP. Он показывает, насколько каждый признак сдвинул каждое решение. Список почти совпал с тем, что нашла статистика в разделе 7: в английском это длина слова и связки, в русском длина связей, порядок слов, союзы и числа. Два независимых способа указали на одно и то же, и это хороший знак.

15. Где модель ошибается

Класс	угадан	чаще всего путается с
en: человек	73%	смешанным
en: ChatGPT	72%	смешанным
en: смешанный	41%	поровну с человеком и ChatGPT
ru: человек	87%	gemma
ru: gpt-4-turbo	88%	gemma
ru: gemma	78%	llama
ru: llama	82%	gemma

Смешанные тексты это самое слабое место. Половина такого текста человеческая, половина машинная, а признаки считаются по всему тексту и дают что-то среднее. Модель видит «ни то ни сё» и гадает. Чтобы ловить такие тексты, нужно смотреть на каждое предложение отдельно и искать, где меняется автор.

В русском модели чаще путаются друг с другом, чем с человеком, особенно gemma и llama, стиль у них похожий. Лучше всех узнаётся gpt-4-turbo.

16. Итог

- Тексты людей и моделей различаются по множеству измеримых свойств, но заметно только по 10–14 из них, и в разных языках это разные свойства.
- Общая тенденция у моделей: синтаксис проще, слова книжнее и плотнее, конкретики (чисел) меньше.
- Пересказ ChatGPT сохраняет смысл оригинала и меняет в основном форму.
- Тексты, которые модель пишет с нуля, шаблонны: похожи друг на друга и предсказуемы.
- По лингвистическим признакам компьютер отличает модель от человека в 84–93% случаев. По словам чуть лучше, но без объяснения, почему.

О чём стоит помнить:

- Признаки посчитаны моим кодом по правилам Profiling-UD, а не самим сайтом. Сайт использует другую программу разбора, поэтому числа могут немного отличаться.
- В русском датасете тексты людей длиннее. Проверки показали, что выводы от этого не ломаются, но классификатор длиной всё-таки пользуется.
- Всё проверялось внутри одного датасета. На текстах новых моделей или из других наук результат может быть хуже, и это отдельный вопрос для исследования.