

Естественные и синтетические научные тексты

Чем тексты, написанные людьми, отличаются от текстов языковых моделей, и насколько хорошо их можно различить автоматически. Без кода, с объяснением терминов.

1. Что за задача	6. Смысл и однообразие
2. Какие данные взяты	7. Классификаторы
3. Как считались признаки текста	8. Где модель ошибается
4. Чем отличаются классы	9. Итог и ограничения
5. Не дело ли в длине	

1. Что за задача

Языковые модели вроде ChatGPT пишут научный текст так гладко, что на глаз его уже трудно отличить от человеческого. Задание состояло из трёх шагов:

- найти измеримые свойства текста, по которым человек и модель заметно отличаются;
- сравнить тексты по смыслу специальными метриками;
- обучить на найденных свойствах несколько классификаторов и оценить их качество.

Признак. Одно число, которое описывает текст. Например, средняя длина слова, доля глаголов или средняя глубина синтаксического дерева. Классификатор видит текст только через набор таких чисел.

2. Какие данные взяты

	Английский, AIGTxt	Русский, AINL-Eval-2025
Что за тексты	Абзацы из научных статей	Аннотации научных статей
Классы	человек, ChatGPT, смешанный	человек, gpt-4-turbo, llama-3.3, gemma-2
Как получен ИИ-текст	ChatGPT пересказал человеческий абзац	Модель написала с нуля по названию и ключевым словам
Взято текстов	4500, по 1500 на класс	4800, по 1200 на источник

В английском наборе у каждого текста есть пара. Это один и тот же абзац в трёх вариантах: оригинал, пересказ ChatGPT и смешанный вариант, где половина от человека, половина от модели. Такая парность пригодится, потому что пересказ можно прямо сравнить с оригиналом. В русском наборе пар нет, все тексты написаны независимо.

Весь набор я не брала, остановилась на нескольких тысячах текстов на язык. Разбор предложений и прогон нейросетей на полном наборе заняли бы много часов, а выводы при таком объёме уже устойчивы.

3. Как считались признаки текста

В задании предложен инструмент Profiling-UD. Он делает синтаксический разбор каждого предложения и по нему считает около ста признаков. Тексты подаются в него отдельно по классам, а результат приходит таблицей.

Синтаксический разбор по стандарту Universal Dependencies (UD). Для каждого слова определяется часть речи, грамматические формы (время, лицо, залог) и слово, от которого оно зависит. Предложение превращается в дерево, у которого можно измерить глубину, длину связей между словами, число придаточных и так далее.

У Profiling-UD есть только веб-форма, программного доступа к нему нет. Поэтому я сделала разбор библиотекой stanza и посчитала по нему те же признаки с теми же названиями, у меня их вышло 99. Разбор по классам сохранён в файлах, так что при желании его можно загрузить в оригинальный сервис и сверить. Признаки делятся на группы:

Группа	Примеры
Текст целиком	число предложений, длина предложения, длина слова
Лексика	разнообразие слов (TTR), доля знаменательных слов
Части речи	доля существительных, глаголов, союзов, чисел
Глагол	время, лицо, залог, причастия и инфинитивы
Синтаксис	глубина дерева, длина связей, типы связей, порядок слов, придаточные

4. Чем отличаются классы

Для каждого признака я проверяла, отличается ли он у человеческих и ИИ-текстов, и насколько сильно.

Статистическая значимость и поправка на множественные сравнения. Тест отвечает на вопрос, могла ли разница получиться случайно. Когда проверяется сто признаков сразу, несколько из них окажутся «значимыми» просто по везению, и поправка (метод Бенджамини–Хохберга) это учитывает.

Размер эффекта, дельта Клиффа. Берём случайный ИИ-текст и случайный человеческий и сравниваем значения признака. Дельта показывает, насколько чаще у ИИ-текста значение окажется больше. Ноль значит, что разницы нет, единица значит, что так бывает всегда. Больше 0.33 это средний эффект, больше 0.47 большой.

На нескольких тысячах текстов значимыми выходят почти все признаки: 71 из 92 в английском и 83 из 92 в русском. Поэтому важнее размер эффекта, и заметным (средним или большим) он оказался у 10 признаков в английском и 14 в русском. Самые сильные из них:

Английский	человек	ИИ	эффект
Средняя длина слова, букв	5.33	5.79	0.60
Вспомогательные глаголы, %	3.96	2.62	-0.52
Связка (is, are), %	1.24	0.63	-0.44
Разнообразие слов, TTR	0.68	0.72	0.42
Доля знаменательных слов	0.59	0.62	0.42
Предложений с глаголом в корне, %	78	88	0.33

Русский	человек	ИИ	эффект
Средняя длина связи между словами	2.45	2.08	-0.54
Сочинительные союзы, %	3.5	5.1	0.46
Самая длинная связь	19.6	12.4	-0.45
Прямые дополнения, %	1.8	3.2	0.42
Числа, %	1.30	0.20	-0.42
Глаголы в прошедшем времени, %	44	27	-0.40
Подлежащее перед сказуемым, %	47	67	0.39

По-простому это выглядит так. В английском ChatGPT при пересказе заменяет простые слова более длинными и книжными, избегает конструкций вида «X is Y» и чаще строит фразу вокруг смыслового глагола. В русском модели пишут проще по синтаксису: связи короче, предложения чаще склеены через «и», порядок слов прямой («подлежащее, сказуемое, дополнение»). Чисел в ИИ-аннотациях почти нет. Это понятно: модель видела только название статьи и не знает, какие там были результаты.

Любопытно, что часть признаков ведёт себя в двух языках противоположно. Например, причастий у ИИ в английском больше, чем у человека, а в русском меньше. Одного универсального набора признаков «машинного текста» не существует, есть только общая тенденция к более простому синтаксису и более плотной лексике.

Смешанные английские тексты по всем главным признакам лежат ровно посередине между человеком и ChatGPT. Это ожидаемо, ведь они и склеены из двух половин. В русском разные модели заметно отличаются друг от друга: у llama почти вдвое больше инфинитивов, у gemma самые короткие тексты, а gpt-4-turbo ближе всех к человеку по длине.

5. Не дело ли в длине

В русском наборе нашлась ловушка. Человеческие аннотации заметно длиннее ИИ-шных: медиана 100 слов против 62–84. А многие признаки от длины зависят, та же самая длинная связь в длинном предложении просто успевает вырасти. Возникает вопрос, не меряем ли мы на самом деле одну длину.

Я проверила это двумя способами. Сначала посчитала частную корреляцию, то есть связь признака с классом после того, как влияние длины вычтено. У большинства признаков она почти не изменилась, а у некоторых даже выросла. Заметно упала она только у самой длинной связи, как и ожидалось. Потом я дала классификатору одну только длину текста. В русском это даёт F1 0.82, так что длина и правда сильная подсказка. Но синтаксические признаки добавляют к ней ещё 10 пунктов, а при различении четырёх источников целых 24. В английском длина ничего не даёт, там все три варианта абзаца примерно одного объёма.

6. Смысл и однообразие

BERTScore. Нейросеть превращает каждое слово в вектор смысла, и дальше каждое слово одного текста ищет самое похожее слово в другом. Итог показывает, насколько тексты близки по смыслу, даже если слова разные. **BARTScore** отвечает на вопрос, насколько вероятно получить один текст из другого по мнению нейросети BART. Чем значение ближе к нулю, тем естественнее переход.

Self-BLEU. Каждый текст класса сравнивается с остальными текстами того же класса по совпадающим сочетаниям слов. Высокое значение означает, что тексты повторяют одни и те же обороты. **Перплексия** показывает, насколько текст неожиданный для языковой модели, у предсказуемого текста она низкая.

Кроме метрик из задания я добавила несколько своих:

- **BARTScore без эталона.** Насколько легко угадать остаток текста по первому предложению.
- **Burstiness.** Насколько сильно перплексия скачет от предложения к предложению. Человек пишет неровно, модель ровнее.
- **Разнообразие словаря** внутри одного текста.

Метрика	Английский	Русский
BERTScore с оригиналом	пересказ 0.66, смешанный 0.81, чужой текст -0.10	пар нет
BARTScore с оригиналом	пересказ -1.9, смешанный -1.1, чужой текст -4.1	пар нет
Похожесть текстов внутри класса	одинаковая	у ИИ выше: 0.67–0.69 против 0.63
Self-BLEU	одинаковый, около 0.10	у ИИ втрое выше: 0.13–0.15 против 0.05
Угадываемость по первому предложению	почти одинаковая	у ИИ заметно выше
Перплексия	у ИИ ниже	почти одинаковая
Burstiness	у ИИ чуть ниже	у ИИ заметно ниже

Выводов здесь два. Первый: пересказ ChatGPT сохраняет смысл оригинала, по обоим метрикам он гораздо ближе к источнику, чем любой другой текст той же тематики. Второй: когда модель пишет с нуля, как в русском наборе, её тексты получаются шаблонными. Они похожи друг на друга, повторяют одни и те же обороты вроде «имеет важное значение для» и предсказуемо развиваются от первого предложения. В английском шаблонности не видно, потому что ChatGPT шёл за чужим текстом и унаследовал его логику и тематику.

По темам классы не различаются, модели писали о том же, о чём и люди. Разница в том, как текст написан, а не о чём он.

7. Классификаторы

Я обучила четыре модели: логистическую регрессию, SVM, случайный лес и XGBoost. Каждой давала несколько наборов признаков и сравнивала результат. Для ориентира добавила две базовые линии. Первая это TF-IDF, классификатор по словам текста. Вторая это метод из бенджмарка mgt-detection-benchmark, где признак всего один, средняя «неуверенность» языковой модели на тексте.

Кросс-валидация. Данные делятся на пять частей, модель учится на четырёх и проверяется на пятой, и так пять раз. В английском важно, чтобы три варианта одного абзаца всегда попадали в одну часть. Иначе модель запомнит тему абзаца, а не стиль, и результат окажется завышенным.

Macro F1. Оценка от 0 до 1, которая учитывает и пропуски, и ложные срабатывания, и считается отдельно по каждому классу, а потом усредняется. Поэтому маленький класс весит столько же, сколько большой.

TF-IDF описывает текст тем, какие слова и пары слов в нём встречаются, с поправкой на то, насколько они редкие.

Задача	только длина	Profiling-UD	+ метрики LM	TF-IDF	бенчмарк
en: человек или ИИ	0.57	0.84	0.87	0.95	0.57
en: человек, ИИ, смешанный	0.37	0.59	0.63	0.67	0.37
ru: человек или ИИ	0.82	0.92	0.93	0.93	0.47
ru: какая из четырёх	0.58	0.82	0.84	0.93	0.27

Macro F1 лучшей из четырёх моделей, пять частей кросс-валидации. «Метрики LM» это перплексия, энтропия, burstiness и разнообразие словаря.

Одни лингвистические признаки дают 0.84 на английском и 0.92 на русском. Метрики языковой модели добавляют ещё 1–4 пункта, значит они несут что-то, чего в синтаксисе нет. Один признак из бенчмарка почти бесполезен, в русском он просто всё называет ИИ. Модели между собой отличаются мало, чаще всех выигрывает SVM.

TF-IDF всё равно сильнее, особенно в английском, где у ChatGPT есть любимые слова, выдающие его сразу. Но у лингвистических признаков другое достоинство: они объяснимы. По ним видно, чем именно отличается текст, а не только что он отличается.

Какие признаки модель использует чаще всего, я проверила методом SHAP. Список почти совпал с найденным статистикой в разделе 4: в английском это длина слова, вспомогательные глаголы и связка, в русском длина связей, порядок слов, союзы и числа. Два независимых способа указали на одно и то же, и это хороший знак.

8. Где модель ошибается

Класс	угадан верно	с чем путается
en: человек	73%	со смешанным, 21%
en: ChatGPT	72%	со смешанным, 18%
en: смешанный	41%	поровну с человеком и ChatGPT
ru: человек	87%	с gemma, 8%
ru: gpt-4-turbo	88%	с gemma, 7%
ru: gemma	78%	с llama, 9%
ru: llama	82%	с gemma, 11%

Смешанные тексты главная слабость. Половина такого текста написана человеком, половина моделью, а признаки усредняются по всему тексту и дают что-то среднее. Чтобы находить такие тексты, нужно смотреть на отдельные предложения, а не на текст целиком. В русском модели чаще путаются друг с другом, чем с человеком, особенно gemma и llama.

9. Итог и ограничения

- ИИ-тексты отличаются от человеческих по многим измеримым признакам, но сильный эффект есть только у 10–14 из них, и в двух языках это разные признаки.
- Пересказ ChatGPT сохраняет смысл оригинала и меняет в основном словарь и синтаксис.
- Тексты, которые модель пишет с нуля, шаблоннее человеческих: они похожи друг на друга и предсказуемы.

- По лингвистическим признакам можно отличить ИИ от человека с F1 0.84–0.93. Слова (TF-IDF) дают чуть больше, но хуже объясняют, в чём разница.

Ограничения, о которых стоит помнить:

- Признаки посчитаны по разбору stanza, а не самим сервисом Profiling-UD, который использует другой парсер. Названия и определения признаков совпадают, но числа могут немного расходиться.
- В русском наборе классы различаются по длине. Основные выводы с поправкой на длину сохраняются, но классификатор длиной всё-таки пользуется.
- Проверка шла внутри каждого набора. Как признаки поведут себя на новых моделях и в других научных областях, здесь не проверялось.